

ワレン・レックス (LEXINGTON WHALEN)

✉ whalenlex[@]gmail.com · 🌐 lxaw.github.io · 🔗 linkedin.com/in/lxaw

概要

大規模言語モデルの効率的な学習・推論を専門とする機械学習研究者。現在、ソフトバンクのSB Intuitionsにて日本最大の大規模言語モデル「Sarashina」シリーズの事前学習・推論最適化研究を共同リード。前職ではNVIDIAのフラッグシップ拡散言語モデル（1-14Bパラメータ）の開発を共同リードし、社内5つ以上の研究チームに採用された学習・推論インフラを構築。ICML、CVPR、ACLにて論文発表。NSF大学院研究フェロー。日米両国において研究チームをリードしてきた実績を有する。

職歴

ソフトバンク – SB Intuitions

事前学習・推論最適化研究リード

東京

2026年4月 –

- ソフトバンクのSB Intuitions R&D部門にて、日本最大の大規模言語モデル「Sarashina」シリーズの事前学習・事後学習最適化研究を共同リード。
- SB Intuitions初となる投機的デコーディング (Speculative Decoding) による推論最適化を構築し、Sarashinaモデルファミリー全体のスループット向上・低遅延化を実現。
- 事前学習・事後学習・推論最適化に関する社内横断的な技術議論において中心的な役割を担い、研究チームとエンジニアリングチームの連携を促進。
- 大規模モデル学習に向けたGPUリソースの評価および長期的なコンピュート戦略の共同策定において、国内外の主要テクノロジー企業と協働。

NVIDIA

効率的深層学習インターン兼データフィルタリングチャレンジリード

アトランタ, GA & サンタクララ, CA

2024年12月 – 2026年3月

- Nemotronシリーズの拡散言語モデルの開発を共同リード。2026年3月公開予定。
- 1-14Bパラメータの拡散言語モデル（ベース・指示・RLバリエーション）EfficientDLMシリーズを共同開発し、Qwen3自己回帰シリーズを精度・速度の両面で上回る成果を達成 (ICML 2026)。成果はCEOジェンスン・ファン氏に直接報告。
- ビジョン言語モデル、エンベディング、潜在推論に関する5つ以上の社内研究チームに採用された学習・評価・推論インフラストラクチャを構築。社内ダウンロード数100万以上。
- 30以上の大学・企業チームが参加するNVIDIAの国際データフィルタリングチャレンジを運営し、Lambda LabsやTuring等のスポンサー企業とGPUリソースの配分を調整。

ジョージア工科大学

機械学習エンジニア

アトランタ, GA

2024年8月 – 2025年12月

- 博士課程・修士課程の3名のチームをリードし、生成品質を維持しつつ拡散モデルの学習時間を最大5倍短縮する手法を設計。CVPR 2025に採択。
- 米国ARPA-HのTHORヘルスケアイニシアチブのアルゴリズムリードとして、がん検知センサーの劣化を70%以上低減し、センサー寿命を数時間から数日へと改善。
- 人体のエネルギーで駆動可能なリソース効率の高い機械学習アーキテクチャを設計し、スタンフォード大学、ノースウェスタン大学、カーネギーメロン大学、MIT等のチームと協働。
- 連邦スポンサーおよびヘルスケア関係者に対し、全国各地で技術的進捗を発表。

主要論文・特許

- L. Whalen, Y. Ito, R. Sakamoto. “Teaching Diffusion to Speculate Left-to-Right.” *Tech Report*, 2026. [SB Intuitions]
- Y. Fu, L. Whalen, A. Garg, C. Wu, M. Khadkevich, N. Oswald, E. Xie, D. Egert, S. Turuvekere Sreenivas, S. Diao, C. Yu, Y. Yu, W. Chen, S. Norouzi, S. Lan, L. Zhu, J. Wang, J. Jiang, M. Mardani, M. Maghoumi, S. Han, A. Jukić, N. Tajbakhsh, J. Kautz, P. Molchanov. “Nemotron-Labs-Diffusion: A Tri-Mode Language Model Unifying Autoregressive, Diffusion, and Self-Speculation Decoding.” *Tech Report*, 2026. [NVIDIA]

- Y. Fu*, **L. Whalen***, Z. Ye, X. Dong, S. Diao, J. Liu, C. Wu, H. Zhang, E. Xie, S. Han, M. Khadkevich, J. Kautz, Y. (Celine) Lin, P. Molchanov. “Efficient-DLM: From Autoregressive to Diffusion Language Models, and Beyond in Speed.” *International Conference on Machine Learning (ICML)*, 2026. [NVIDIA]
- Y. Fu, **L. Whalen**, X. Dong, S. Diao, C. Wu, E. Xie, S. Han, J. Kautz, Y. (Celine) Lin, P. Molchanov. “Training Framework for Converting Autoregressive Language Models into Faster Diffusion Language Models.” 米国特許、出願予定, 2026. [NVIDIA]
- C. Shih, C. Li, C. Yu, H. Fang, S. Li, W. Hsin, **L. Whalen**, H. Suh, G. Eisenhauer, L. Liu, Y. (Celine) Lin. “NeRArch-Sim: A Unified Simulator for Benchmarking and DSE of Neural Rendering Accelerators.” *International Symposium on Computer Architecture (ISCA)*, 2026. [ジョージア工科大学]
- **L. Whalen***, Z. Du*, H. You*, C. Li, S. Li, Y. (Celine) Lin. “Early-Bird Diffusion: Investigating and Leveraging Timestep-Aware Early-Bird Tickets in Diffusion Models for Efficient Training.” *IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2025. [ジョージア工科大学]
- Z. Ye, Z. Wang, K. Xia, J. Hong, L. Li, **L. A. Whalen**, C. Wan, H. You, C. Lin, S. Kundu. “LAMB: A Training-Free Method to Enhance the Long-Context Understanding of SSMs via Attention-Guided Token Filtering.” *Association for Computational Linguistics (ACL)*, 2025. [ジョージア工科大学]
- A. Murphy, **L. Whalen**, S. Dubinsky, M. Gavin, J. F. Bailyn, J. Ginn. “On ‘historical unity’ of Russian and Ukrainian: A linguistic perspective on language conflict and change.” *Linguistic Society of America (LSA)*, 2023年4月. [サウスカロライナ大学]

* 等貢献 (Equal contribution)

招待講演

- 「拡散言語モデル：基本から応用まで」、ソフトバンク – SB Intuitions 2026年6月
- 入社式スピーチ、ソフトバンク 2026年4月

学歴

ジョージア工科大学	アトランタ, GA
大学院研究員 – 効率的機械学習システム	2024年8月 – 2025年12月

サウスカロライナ大学オナーズカレッジ	コロンビア, SC
コンピュータサイエンス加速修士課程	2021年1月 – 2024年8月

受賞・表彰

- ソフトバンクグループ代表 (2026年入社式) 2026年3月
- NSF大学院研究フェローシップ (150,000ドル相当) 2024年4月
- 東洋大学交換留学生代表 2023年7月
- サウスカロライナ大学 2023年度優秀卒業生 2023年2月
- 米務省日本語クリティカル・ランゲージ・スカラー 2023年1月
- サウスカロライナ大学トップスカラー (100,000ドル以上相当) 2020年8月

語学力

- 英語 – ネイティブ
- 日本語 – ネイティブレベル (日本語能力試験N1認定)
- 中国語 – 中級
- ドイツ語 – 初級