

ワレン・レックス (LEXINGTON WHALEN)

✉ whalenlex[[@](mailto:whalenlex[at]gmail.com)]gmail.com · [lxaw.github.io](https://github.com/lxaw) · [linkedin.com/in/lxaw](https://www.linkedin.com/in/lxaw) · [Google Scholar](https://scholar.google.com/citations?user=whalenlex)

概要

フロンティアAIと日米のテクノロジー連携が交差する領域にて、大規模言語モデル (LLM) の効率的な学習・推論を専門とする機械学習研究者。NVIDIA初の拡散言語モデルシリーズ (Nemotron-Labs-Diffusion、Efficient-DLM) を共同開発し、その後ソフバンクのSB IntuitionsにてSarashina LLMの事前学習・推論最適化をリード。2026年11月にNVIDIA Research (DLER) へ入社予定。EMNLP・ICML・CVPR・ACLにおいて論文発表。NSF大学院研究フェロー。

学歴

ジョージア工科大学
コンピュータサイエンス修士課程 (人工知能専攻)
NSF大学院研究フェロー。

アトランタ, GA
2027年春修了予定

サウスカロライナ大学オナーズカレッジ
コンピュータサイエンス学士・修士一貫課程
2023年度 優秀卒業生 (Outstanding Senior)。

コロンビア, SC
2021年1月 - 2024年8月

査読付き論文

- [1] Y. Fu, **L. Whalen**, A. Garg, C. Wu, M. Khadkevich, N. Oswald, E. Xie, D. Egert, S. Turuvekere Sreenivas, S. Diao, C. Yu, Y. Yu, W. Chen, S. Norouzi, S. Lan, L. Zhu, J. Wang, J. Jiang, M. Mardani, M. Maghoumi, S. Han, A. Jukić, N. Tajbakhsh, J. Kautz, P. Molchanov. “Nemotron-Labs-Diffusion: A Tri-Mode Language Model Unifying Autoregressive, Diffusion, and Self-Speculation Decoding.” **EMNLP**, 2026. [NVIDIA]
- [2] Y. Fu*, **L. Whalen***, Z. Ye, X. Dong, S. Diao, J. Liu, C. Wu, H. Zhang, E. Xie, S. Han, M. Khadkevich, J. Kautz, Y. (Celine) Lin, P. Molchanov. “Efficient-DLM: From Autoregressive to Diffusion Language Models, and Beyond in Speed.” **ICML**, 2026. [NVIDIA]
- [3] C. Shih, C. Li, C. Yu, H. Fang, S. Li, W. Hsin, **L. Whalen**, H. Suh, G. Eisenhauer, L. Liu, Y. (Celine) Lin. “NeRArch-Sim: A Unified Simulator for Benchmarking and DSE of Neural Rendering Accelerators.” **ISCA**, 2026. [Georgia Tech]
- [4] **L. Whalen***, Z. Du*, H. You*, C. Li, S. Li, Y. (Celine) Lin. “Early-Bird Diffusion: Investigating and Leveraging Timestep-Aware Early-Bird Tickets in Diffusion Models for Efficient Training.” **CVPR**, 2025. [Georgia Tech]
- [5] Z. Ye, Z. Wang, K. Xia, J. Hong, L. Li, **L. Whalen**, C. Wan, Y. Fu, Y. (Celine) Lin, S. Kundu. “LAMB: A Training-Free Method to Enhance the Long-Context Understanding of SSMs via Attention-Guided Token Filtering.” **ACL**, 2025. [Georgia Tech]
- [6] A. Murphy, **L. Whalen**, S. Dubinsky, M. Gavin, J. F. Bailyn, J. Ginn. “On ‘historical unity’ of Russian and Ukrainian: A linguistic perspective on language conflict and change.” **LSA**, 2023年4月. [University of South Carolina]

* 共同筆頭著者 (Equal contribution)

プレプリント・技術報告

- [1] **L. Whalen**, Y. Ito, R. Sakamoto. “KBBQ: A Predictive Noise Law and the Limits of Spectrum Flattening in FP4 Quantization.” Technical Report, 2026. [SB Intuitions]
- [2] **L. Whalen**, Y. Ito, R. Sakamoto. “Teaching Diffusion to Speculate Left-to-Right.” Technical Report, 2026. Under review at TMLR. [SB Intuitions]

特許

- [1] **L. Whalen**, Y. Ito, R. Sakamoto. 「拡散ベースの投機的ドラフトモデルにおける受理長改善アルゴリズム」日本国特許 (出願済み), 2026. [SB Intuitions]
- [2] Y. Fu, **L. Whalen**, X. Dong, S. Diao, C. Wu, E. Xie, S. Han, J. Kautz, Y. (Celine) Lin, P. Molchanov. “Training Framework for Converting Autoregressive Language Models into Faster Diffusion Language Models.” 米国特許 (出願済み), 2026. [NVIDIA]

研究経歴

NVIDIA Research – **DLERチーム**
Research Scientist

サンタクララ, CA
2026年11月 –

- Making intelligence efficient.

ソフトバンク – **SB Intuitions**
事前学習・推論最適化研究リード

東京
2026年4月 – 2026年11月

- 日本最大の大規模言語モデル「Sarashina」シリーズの事前学習・事後学習最適化研究を、ソフトバンクのSB Intuitions R&D部門にて共同リード。
- 最大100Bパラメータ規模のモデルを対象に、新規の量子化手法開発をリード。
- SB Intuitions初となる投機的デコーディング推論基盤をSarashinaファミリー向けに構築。学習時のドラフト整合手法を提案し、位置様なベースラインと比較して受理ドラフト長を21～76%向上。
- 事前学習・事後学習・推論最適化に関する日本語での部門横断的な技術議論において中心的な技術的役割を担い、研究とエンジニアリングの橋渡しを行うとともに、大規模学習に向けたGPUリソースの評価および長期的なコンピュータ戦略の共同策定において国内外の主要テクノロジー企業および政府機関と協働。

NVIDIA – **DLERチーム**
効率的深層学習インターン兼データフィルタリングチャレンジ・リード
メンター：Dr. Pavlo Molchanov・Yonggan Fu (NVIDIA Research)。

アトランタ, GA & サンタクララ, CA
2024年12月 – 2026年3月

- 自己回帰・拡散・自己投機の3モードを統合した言語モデルファミリー **Nemotron-Labs-Diffusion** (3B～14B規模, EMNLP 2026採択) を共同開発。8Bモデルは同等精度でQwen3-8Bの6倍のトークンを1回の順伝播でデコードし (最大4倍のスループット)、**Hugging Face**で公開、累計ダウンロード数は約100万。
- **Efficient-DLM** (ICML 2026) の共同筆頭著者。事前学習済み自己回帰モデルを拡散言語モデルへ変換し、8BモデルはDream 7B / Qwen3 4Bと比べて精度+5.4%/+2.7%、スループット4.5倍/2.7倍を達成 (**Hugging Face**でオープンウェイト公開)。成果はCEOジェンソン・フアン氏に直接報告。
- NVIDIA初の拡散言語モデルシリーズ向けの学習・評価・推論インフラの構築に携わり、ビジョン言語モデル・埋め込み・潜在推論に関する社内の5チーム以上の研究チームに採用。
- 30以上の大学・企業チームが参加するNVIDIAの**2025 International Data Filtering Challenge for Training Edge Language Models**を運営。

ジョージア工科大学
大学院研究員

アトランタ, GA
2024年8月 – 2025年12月

- 博士・修士課程の学生3名のチームをリードし、生成品質を維持しつつ拡散モデルの学習時間を2.9～5.8倍 (標準的なtrain-prune-finetuneと比較して最大10.3倍) 短縮。CVPR 2025採択。
- 米国**ARPA-H THORヘルスケアイニシアチブ**のアルゴリズムリードとして、スタンフォード大学・ノースウェスタン大学・カーネギーメロン大学・MITのチームと協働し、人体のエネルギーで駆動するリソース効率の高い機械学習アーキテクチャを設計。がん検知センサーの劣化を70%以上低減し、センサー寿命を数時間から数日へ延長。

受賞・表彰

- | | |
|--------------------------------------|---------|
| • ソフトバンクグループ代表 (2026年入社式) | 2026年3月 |
| • NSF大学院研究フェローシップ (150,000ドル相当) | 2024年4月 |
| • 東洋大学交換留学生代表 | 2023年7月 |
| • サウスカロライナ大学 2023年度 優秀卒業生 | 2023年2月 |
| • 米国務省 日本語クリティカル・ランゲージ・スカラー | 2023年1月 |
| • サウスカロライナ大学 トップスカラー (100,000ドル以上相当) | 2020年8月 |

招待講演

- | | |
|---|----------|
| • 「速く、小さく、軽く：LLM効率化のベストプラクティス」、ソフトバンク – SB Intuitions | 2026年10月 |
| • 「拡散言語モデル：基本から応用まで」、ソフトバンク – SB Intuitions | 2026年7月 |
| • 入社式スピーチ、ソフトバンク | 2026年4月 |

アドバイザー

- 日米のAI・技術政策に関するアドバイザーとして、在日米国大使館および日本政府関係者と協力。

語学力

英語 (ネイティブ) ・ 日本語 (ネイティブレベル、日本語能力試験N1認定) ・ 中国語 (中級)